

Zaman Serisi Analizi Raporu: Tesla Hisse Kapanış Fiyatları Tahmini

Bu rapor, Tesla hisse senedi kapanış fiyatlarını tahmin etmek için LSTM modeli ve çeşitli teknik göstergelerin kullanımına odaklanmaktadır. Modelin ortalama bir performans sergilediği gözlemlenmiştir.

Veri Seti ve Ön İşleme adımları

Veriler Kaggle platformundan elde edilmiştir. Kullanılan sütunlar: Date (Tarih), Open (Açılış Fiyatı), High (Günün En Yüksek Fiyatı), Low (Günün En Düşük Fiyatı), Close (Kapanış Fiyatı) ve Volume (Hacim).

Veri setinde eksik veri kontrolü yapıldı. Bu, modelin başarısını doğrudan etkileyen bir durumu varsa ortadan kaldırmaya yönelik bir aşamadır.

LSTM modeli zamana bağlı ardışık öğrenme geliştirdiği için "Date" sütunu 'datetime' formatına dönüştürüldü.

Derin öğrenme modelleri sayısal verilere ihtiyaç duyar. Bu sayısal verilerin büyük ölçekli olması birden fazla dezavantaj sunabilir. Bu sebeple veriler, 0-1 aralığında MinMaxScaler kullanılarak ölçeklendirildi. Bu sayede eğitim sürelerinin uzamasının önüne geçilmiş oldu ve modelin genelleme başarısı artırılmış oldu.

Son olarak veriler, modele verilmeden önce LSTM'e uygun hale getirildi. LSTM için veriler; Veri setindeki örnek sayısı, her bir örnek için kullanılan geçmiş zaman adımı sayısı (60 gün olarak belirlendi) ve her bir zaman adımında kullanılan özellik sayısı (kapanış fiyatı, RSI, MACD, hacim) formatına dönüştürüldü ve modele verildi. Bu formata göre, model 60 günlük kapanış fiyatlarına ve RSI, MACD, Bollinger Bantları ve diğer özelliklere bakarak bir sonraki günün kapanış fiyatını tahmin edebilecek.

Teknik Göstergeler

Model performansını artırmak için RSI, MACD, Bollinger Bantları gibi teknik göstergeler hesaplandı ve veri setine dahil edildi.

- RSI (Relative Strength Index): Piyasanın aşırı alım veya satımda olup olmadığını gösterir. Fiyatın çok hızlı bir şekilde yükseldiği veya düştüğü durumlarda düzeltme (geri çekilme) olabileceğini gösterir.

- MACD (Moving Average Convergence Divergence): Fiyat trendlerinin yönünü ve momentumunu belirlemeye yardımcı olur. Fiyatların yukarı veya aşağı yönlü hız kazandığı dönemleri gösterir ve trend değişim sinyalleri verir.

- Bollinger Bantları: Piyasanın volatilitasını (oyunluk) ve aşırı alım-satım bölgelerini belirlemek için kullanılır. Fiyatın belirli bir hareketli ortalama ne kadar uzaklaştığını gösterir. Bu teknik göstergeleri kullanmak, yalnızca kapanış fiyatları üzerinden tahmin yapmaya kıyasla modelin piyasa hareketlerini daha iyi anlamasına yardımcı olur ve daha düşük hata (RMSE) ile daha güvenilir tahminler yapmasını sağlar.

Model Geliştirme ve optimizasyon

Model seçiminde uzun bağımlılıkları işleyebilmesi ve karmaşık verilerde başarılı olması sebebiyle LSTM tercih edildi. Model mimarisinde 2 LSTM katmanı ve bu katmanlarda 50 nöron tercih edildi. Bu sayede hem hızlı eğitim hem de düşük hata elde edilmesi hedeflendi.

LSTM katmanlarından sonra 0.2 oranında dropout katmanları eklendi. Dropout katmanı ile tüm nöronların rastgele 0.2'si devre dışı bırakıldı ve aşırı öğrenmenin önüne geçildi. Dropout oranı için [0.1, 0.2, 0.5] oranları denendi. En optimumu 0.2 olarak belirlendi.

Learning Rate hiper parametresi için [0.001, 0.01, 0.1] değerleri test edildi ve denemeler sonucunda 0.001 belirlendi. Bu değer modelin her adımda ağırlıkları ne kadar hızlı güncelleyeceğini belirler.

Epoch sayısı için [10, 20, 50, 100] deęerleri test edildi ve en yksek bařarı 100 epoch'ta elde edildi. Bu deęer modelin tm eęitim verisini ka defa kullanarak ęrenimi yapacaęını belirler.

Batch Size hiper parametresi iin ilk ařamada 32 belirlendi. Eęitim srelerinin uzaması ve GPU yetersizlięinden dolayı deęiřtirilmedi.


Deęerlendirme

Model performansı, Root Mean Square Error (RMSE) ile deęerlendirildi. Bu metrik tahmin edilen deęerler ile gerek deęerlerin arasındaki ortalama hatayı temsil eder.

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (Predicted_i - Actual_i)^2}{N}}$$

řekil1. RMSE matematiksel gsterim

En optimal parametrelerle modeli eęitimi tamamlandı. Test verisindeki RMSE deęeri:18 olarak hesaplandı. Bu deęer ortalama bir bařarı olarak deęerlendirildi ve sonular grselleřtirildi. Hiper parametre optimizasyonunu elle deneyerek deęil bir algoritma yardımıyla yapmak modelin bařarısını arttıracaktır.



řekil 2. Model bařarısı